

LAPORAN AKHIR
PROJECT BASED LEARNING

**"Implementasi Multi Feature Extraction dan Komparasi Algoritma SVM serta
XGBoost Berbasis Mobile Menggunakan ONNX untuk Klasifikasi Uang Rupiah"**

Dosen Pengampu:

Dr. Ely Setyo Astuti, S.T., M.T.

Yoppy Yunhasnawa, S.ST., M.Sc.



Disusun Oleh:

Abdullah Shamil Basayev	(2341720166)
Achmad Diaz Hikmal Baihaqi	(2341720228)
Adinda Mirza Devani	(2341720046)
Luthfiyyah Adzka Nur Sabrina	(2341720148)
Moch. Alfin Burhanudin Alqodri	(2341720024)

JURUSAN TEKNOLOGI INFORMASI
PROGRAM STUDI D-IV TEKNIK INFORMATIKA
POLITEKNIK NEGERI MALANG

2025

LEMBAR PENGESAHAN LAPORAN AKHIR PBL

"Implementasi Multi Feature Extraction dan Komparasi Algoritma SVM serta XGBoost Berbasis Mobile Menggunakan ONNX untuk Klasifikasi Uang Rupiah"

Disusun Oleh:

Abdullah Shamil Basayev	2341720166
Achmad Diaz Hikmal Baihaqi	2341720228
Adinda Mirza Devani	2341720046
Luthfiyyah Adzka Nur Sabrina	2341720148
Moch. Alfin Burhanudin Alqodri	2341720024

Telah diresmikan pada tanggal 18 Desember 2025

Dengan Penguji:

- | | | | |
|----|--------------------------------------|---|-------|
| 1. | Pengolahan
Citra Visi
Komputer | : <u>Prof. Dr. Eng. Cahya Rahmad, S.T., M.Kom.</u>
NIP. 197202022005011002 | |
| 2. | Machine
Learning | : <u>Dr. Ely Setyo Astuti, S.T., M.T</u>
NIP. 197605152009122001 | |
| 3. | Pemrograman
Mobile | : <u>Yoppy Yunhasnawa, S.ST., M.Sc.</u>
NIP. 198906212019031013 | |

Mengetahui

Ketua Jurusan Teknologi Informasi

Ketua Program Studi
D4 Teknik Informatika

Mungki Astiningrum, S.T., M.Kom.
NIP. 19771030200501200

Dr. Ely Setyo Astuti, S.T., M.T
NIP. 197605152009122001

DAFTAR ISI

LEMBAR PENGESAHAN LAPORAN AKHIR PBL	i
DAFTAR ISI.....	ii
DAFTAR GAMBAR.....	v
DAFTAR TABEL	vi
BAB I.....	1
PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Batasan Masalah	2
1.5 Manfaat.....	3
1.5.1 Manfaat Teoretis	3
1.5.2 Manfaat Praktis	3
BAB II	5
LANDASAN TEORI	5
2.1 Pengolahan Citra Digital.....	5
2.2 Uang Rupiah Tahun Emisi 2022	5
2.3 Pra-pemrosesan Citra (<i>Image Preprocessing</i>)	5
2.3.1 Konversi Ruang Warna (<i>Grayscale</i>).....	5
2.3.2 Gaussian Blur	6
2.3.3 Adaptive Otsu Thresholding & Masking.....	6
2.4 Ekstraksi Fitur (<i>Feature Extraction</i>).....	6
2.4.1 HSV Color Histogram (Warna)	6
2.4.2 Local Binary Patterns (LBP) (Tekstur).....	7
2.4.3 Hu Moments (Bentuk).....	7
2.5 Algoritma Klasifikasi (<i>Machine Learning</i>)	8
2.5.1 Support Vector Machine (SVM).....	8
2.5.2 Extreme Gradient Boosting (XGBoost).....	8
2.6 Teknologi Implementasi	9

2.6.1 ONXX (<i>Open Neural Network Exchange</i>)	9
2.6.2 Supabase	9
2.7 Evaluasi Kinerja Model.....	9
BAB III.....	10
METODOLOGI.....	10
3.1 Alur Penelitian.....	10
3.2 Pengumpulan Data (Data Collection)	10
3.3 Pre-processing	11
3.4 Ekstraksi Fitur	11
3.4.1 Fitur Warna (HSV)	12
3.4.2 Fitur Tekstur (<i>Local Binary Pattern</i> – LBP)	12
3.4.3 Fitur Bentuk (<i>Hu Moments</i>).....	12
3.5 Pemodelan dan Pelatihan (<i>Modeling</i>).....	12
3.5.1 <i>Support Vector Machine</i>	12
3.5.2 XGBoost (<i>Extreme Gradient Boosting</i>) V2	12
3.6 Konversi dan Implementasi Sistem	13
3.7 Evaluasi Kinerja.....	13
BAB IV	14
HASIL & ANALISA	14
4.1 Implementasi Sistem	14
4.1.1 Lingkungan Implementasi	14
4.1.2 Hasil Preprocessing Citra.....	14
4.1.3 Implementasi Antarmuka Aplikasi	15
4.2 Hasil Pengujian Model	17
4.2.1 Pengujian Skenario 1: <i>Support Vector Machine</i> (SVM).....	18
4.2.2 Pengujian Skenario 2: <i>Extreme Gradient Boosting</i> (XGBoost).....	18
4.2.3 Perbandingan Kinerja Model	19
4.3 Pengujian Implementasi Mobile (ONNX)	20
4.3.1 Kecepatan Inferensi	20
4.3.2 Pengujian Fungsionalitas (Supabase)	20
4.4 Pembahasan.....	20
BAB V	22

KESIMPULAN DAN SARAN	22
5.1 Kesimpulan.....	22
5.2 Saran	22
DAFTAR PUSTAKA	24

DAFTAR GAMBAR

Gambar 2.1 Proses Konversi Citra RGB ke Grayscale dan Biner	5
Gambar 2.2 Model Ruang Warna HSV (Hue, Saturation Value).....	7
Gambar 2.3 Ilustrasi Perhitungan Nilai LBP pada Piksel Citra.	7
Gambar 2.4 Konsep Hyperplane dan Margin pada SVM.	8
Gambar 2.5 Ilustrasi Struktur Pohon Keputusan (Decision Tree)	9
Gambar 3.1 Sample Dataset.....	11
Gambar 3.2 Alur Preprocessing	11
Gambar 4.1 Halaman Home 1	15
Gambar 4.2 Halaman Home 2	15
Gambar 4.3 Halaman Login.....	16
Gambar 4.4 Halaman SignUp	16
Gambar 4.5 Halaman Deteksi	17
Gambar 4.6 Halaman Riwayat	17
Gambar 4.7 Hasil Klasifikasi SVM	18
Gambar 4.8 Heatmap SVM.....	18
Gambar 4.9 Hasil Klasifikasi XGBoost.....	19
Gambar 4.10 Heatmap XGBoost	19

DAFTAR TABEL

Tabel 4.1 Tabel Perbandingan Kinerja Model.....	19
Tabel 4.2 Tabel Pengujian Fungsionalitas.....	20

BAB I

PENDAHULUAN

1.1 Latar Belakang

Uang kartal merupakan instrumen pembayaran yang sah dan memegang peranan vital dalam stabilitas ekonomi Indonesia. Di Indonesia, Bank Indonesia menerbitkan Uang Rupiah kertas dalam berbagai pecahan nominal dengan karakteristik visual yang khas. Meskipun setiap pecahan memiliki perbedaan warna dan desain, proses identifikasi nominal secara cepat dan akurat masih menjadi tantangan tersendiri dalam situasi tertentu, misalnya ketika kondisi fisik uang mengalami degradasi kualitas (lusuh/pudar) atau bagi sistem otomatisasi yang menuntut presisi tinggi.

Perkembangan teknologi *Computer Vision* dan *Machine Learning* menawarkan solusi praktis untuk otomatis pengenalan objek tersebut. Namun, tantangan teknis utama muncul ketika sistem ini harus diimplementasikan pada perangkat mobile. Mayoritas pendekatan modern saat ini sangat bergantung pada algoritma *Deep Learning*, seperti *Convolution Neural Network* (CNN). Meskipun memiliki akurasi tinggi, metode tersebut cenderung membebani kinerja perangkat keras (*hardware*), menguras daya baterai, dan membutuhkan kapasitas penyimpanan yang besar. Oleh karena itu, diperlukan strategi rekayasa fitur (*feature engineering*) yang lebih efisien untuk mengekstraksi informasi visual tanpa memerlukan daya komputasi yang berlebihan (Chen & Guestrin, 2016).

Untuk mengatasi keterbatasan sumber daya tersebut, diperlukan strategi rekayasa fitur yang lebih ringan namun tetap handal. Penelitian ini mengusulkan pendekatan *Multi Feature Extraction* yang menggabungkan tiga parameter utama untuk menangkap karakteristik unik uang Rupiah. Pertama, fitur Warna diekstraksi menggunakan HSV Histogram. (Smith & Chang, 1997) menekankan bahwa ruang warna HSV lebih unggul daripada RGB dalam memisahkan informasi kromatik dari intensitas cahaya, sehingga lebih konsisten terhadap perubahan pencahayaan. Kedua, fitur Tekstur diekstraksi menggunakan *Local Binary Pattern* (LBP). Metode yang dikembangkan oleh (Shen & He, 2011) ini terbukti efisien secara komputasi dan invarian terhadap skala abu-abu, sangat cocok untuk mengenali pola serat pada uang kertas. Ketiga, fitur Bentuk diekstraksi menggunakan *Hu Moments* (Ming-Kuei, 1962), yang menjamin invarian rotasi agar uang tetap terdeteksi meskipun posisi pengambilan gambar miring.

Selain ekstraksi fitur, pemilihan algoritma klasifikasi juga menjadi fokus utama. Penelitian ini melakukan studi komparasi antara dua algoritma *Machine Learning* terkemuka, yaitu *Support Vector Machine* (SVM) dan *Extreme Gradient Boosting* (XGBoost). (Farhat, 1992) menyatakan bahwa SVM efektif dalam ruang berdimensi tinggi, sementara (Chen & Guestrin, 2016) menonjolkan kemampuan XGBoost dalam hal kecepatan dan skalabilitas melalui pendekatan *tree boosting*.

Guna menjembatani kesenjangan antara model *Machine Learning* yang kompleks dan lingkungan *mobile* yang terbatas, penelitian ini menerapkan konversi model ke format ONNX (*Open Neural Network Exchange*). (Qin et al., 2025) menjelaskan bahwa ONNX memungkinkan interoperabilitas model antar-*framework* dan optimalisasi inferensi pada berbagai perangkat keras. Dengan format ini, model klasifikasi dapat dijalankan secara lokal (*on-device*) pada aplikasi *mobile* bernama "*Monerize*", yang juga terintegrasi dengan basis data untuk fitur manajemen akun dan riwayat deteksi.

Berdasarkan uraian di atas, penelitian ini mengangkat judul "**Implementasi Multi Feature Extraction dan Komparasi Algoritma SVM serta XGBoost Berbasis Mobile Menggunakan ONNX untuk Klasifikasi Uang Rupiah**". Proyek ini bertujuan membuktikan bahwa kombinasi fitur hibrida dan optimasi model ONNX dapat menghasilkan sistem deteksi uang yang akurat, efisien, dan siap pakai pada perangkat *mobile*.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalahnya adalah

1. Bagaimana perbandingan kinerja algoritma *Support Vector Machine* (SVM) dan *Extreme Gradient Boosting* (XGBoost) dalam mengklasifikasikan 8 kelas data (nominal uang dan *negative*) menggunakan pendekatan *Multi Feature Extraction*?
2. Bagaimana mengimplementasikan model *Machine Learning* yang telah dilatih ke dalam format ONNX pada aplikasi *mobile* agar dapat berjalan secara lokal (*on-device*) dengan efisien dan integrasi dengan basis data?

1.3 Tujuan

Berdasarkan rumusan masalah yang dipaparkan, tujuan dari project ini adalah

1. Menganalisis dan membandingkan kinerja algoritma *Support Vector Machine* (SVM) dan *Extreme Gradient Boosting* (XGBoost) dalam mengklasifikasikan 8 kelas data (7 nominal uang dan 1 *negative*) menggunakan metode *Multi Feature Extraction*, guna menentukan model dengan akurasi dan stabilitas terbaik.
2. Mengimplementasikan model *Machine Learning* terpilih ke dalam format ONNX pada aplikasi *mobile* "Monerize", sehingga sistem dapat melakukan deteksi secara lokal (*on-device*) dengan efisien serta terintegrasi dengan basis data untuk fitur manajemen akun dan riwayat.

1.4 Batasan Masalah

Agar pembahasan ini lebih terarah dan fokus pada tujuan yang ingin dicapai, kami menetapkan beberapa batasan masalah sebagai berikut.

1. Objek Penelitian:

- Objek yang diklasifikasikan adalah uang kertas Rupiah emisi yang berlaku saat ini, terdiri dari 7 kelas nominal (Rp1.000, Rp2.000, Rp5.000, Rp10.000, Rp20.000, Rp50.000, Rp100.000) dan 1 kelas *negative* (bukan uang).
- Penelitian ini tidak mencakup klasifikasi uang logam (koin).

2. Metode dan Algoritma:

- Sistem tidak menggunakan *Deep Learning* (seperti CNN), melainkan menggunakan pendekatan *Machine Learning* konvensional dengan *Multi Feature Extraction* (Warna HSV, Tekstur LBP, dan Bentuk Hu Moments).
- Teknik *preprocessing* citra menerapkan metode *Adaptive Otsu Thresholding* dan *Masking* untuk memisahkan objek uang dari latar belakang (*background*).
- Algoritma yang dibandingkan performanya dibatasi pada *Support Vector Machine* (SVM) dan *Extreme Gradient Boosting* (XGBoost).

3. Implementasi Sistem:

- Model *Machine Learning* yang telah dilatih dikonversi ke format ONNX (*Open Neural Network Exchange*) agar dapat dijalankan secara lokal (*on-device*) pada perangkat *mobile*.
- Fitur aplikasi *mobile* mencakup identifikasi nominal, manajemen akun (*Login/Register*), dan penyimpanan riwayat deteksi (*History*) yang terintegrasi dengan layanan Supabase.
- Pengembangan aplikasi difokuskan pada platform Android.

4. Fungsional dan Lingkungan:

- Sistem dirancang untuk mengidentifikasi nominal uang, bukan untuk mendeteksi keaslian uang (uang palsu).
- Pengambilan citra diasumsikan dilakukan dengan pencahayaan yang cukup dan uang tidak dalam kondisi rusak parah (sobek hancur).

1.5 Manfaat

Hasil dari penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

1.5.1 Manfaat Teoretis

1. **Pengembangan Ilmu Komputer:** Memberikan bukti empiris mengenai efektivitas metode ekstraksi fitur hibrida (*hybrid features*) yang menggabungkan karakteristik warna (HSV), tekstur (*Local Binary Patterns*), dan invarian bentuk (*Hu Moments*) dalam meningkatkan robustas pengenalan objek pada citra uang kertas.
2. **Referensi Akademis:** Menjadi rujukan bagi peneliti selanjutnya dalam membandingkan kinerja algoritma *Support Vector Machine* (SVM) dan *XGBoost* pada kasus klasifikasi multikelas dengan fitur berdimensi tinggi, khususnya dalam domain *Computer Vision*.

1.5.2 Manfaat Praktis

1. **Bagi Penulis:** Meningkatkan pemahaman teknis mengenai implementasi *end-to-end Machine Learning*, mulai dari pra-pemrosesan citra, ekstraksi fitur hibrida, hingga integrasi model ONNX pada platform Android.

2. **Bagi Pengguna:** Menyediakan aplikasi praktis yang membantu identifikasi nominal uang Rupiah secara akurat, dilengkapi dengan fitur riwayat digital untuk memantau aktivitas deteksi yang telah dilakukan.
3. **Bagi Sektor UMKM dan Ritel:** Memberikan referensi studi komparasi mengenai efektivitas algoritma SVM dan XGBoost dengan pendekatan fitur hibrida, sebagai alternatif solusi yang lebih ringan dibandingkan *Deep Learning* untuk perangkat *mobile*.

BAB II

LANDASAN TEORI

2.1 Pengolahan Citra Digital

Pengolahan citra digital adalah disiplin ilmu yang mempelajari teknik manipulasi citra menggunakan komputer untuk meningkatkan kualitas citra atau mengekstraksi informasi penting darinya. Citra digital secara matematis didefinisikan sebagai fungsi dua dimensi $f(x, y)$, di mana x dan y adalah koordinat spasial, dan nilai amplitudo f di titik tersebut disebut intensitas atau *gray level* (Gonzalez & Woods, 2018).

Citra digital tersusun dari elemen-elemen diskrit yang disebut piksel (*picture element*). Dalam penelitian ini, pengolahan citra menjadi fondasi utama untuk mengubah data visual mentah dari kamera *smartphone* menjadi data numerik yang dapat diproses oleh algoritma pembelajaran mesin.



Gambar 2.1 Proses Konversi Citra RGB ke Grayscale dan Biner

2.2 Uang Rupiah Tahun Emisi 2022

Objek utama dalam penelitian ini adalah Uang Rupiah Kertas Tahun Emisi (TE) 2022 yang diterbitkan oleh Bank Indonesia. Uang emisi baru ini memiliki desain, ukuran, dan fitur keamanan yang diperbarui dibandingkan emisi sebelumnya. Terdapat tujuh pecahan nominal yang digunakan sebagai kelas klasifikasi, yaitu: Rp1.000, Rp2.000, Rp5.000, Rp10.000, Rp20.000, Rp50.000, dan Rp100.000. Setiap pecahan memiliki karakteristik dominan berupa warna dasar dan ukuran fisik yang berbeda, yang menjadi acuan utama dalam proses ekstraksi fitur.

2.3 Pra-pemrosesan Citra (*Image Preprocessing*)

Preprocessing ini bertujuan untuk mempersiapkan citra sebelum masuk ke tahap ekstraksi fitur. Tahapan ini krusial untuk menghilangkan *noise*, menyederhanakan data, dan memisahkan objek dari latar belakang.

2.3.1 Konversi Ruang Warna (*Grayscale*)

Citra asli dari kamera umumnya berformat RGB (*Red, Green, Blue*). Untuk keperluan pemrosesan tekstur dan bentuk, citra dikonversi menjadi citra keabuan (*grayscale*). Rumus standar yang digunakan adalah:

$$Y = 0.299 \cdot R + 0.587 \cdot G + 0.114 \cdot B$$

Dimana Y adalah intensitas keabuan.

2.3.2 Gaussian Blur

Untuk mengurangi *noise* atau derau yang mungkin muncul akibat kualitas kamera atau pencahayaan, digunakan filter *Gaussian Blur*. Metode ini melakukan konvolusi citra dengan kernel *Gaussian* untuk menghaluskan citra tanpa menghilangkan tepi objek secara signifikan.

2.3.3 Adaptive Otsu Thresholding & Masking

Segmentasi objek dilakukan menggunakan metode *Otsu Thresholding*. Metode ini secara otomatis menghitung nilai ambang batas (*threshold*) optimal yang meminimalkan varians intra-kelas, sehingga dapat memisahkan objek (uang) dari latar belakang secara biner (hitam dan putih).

Hasil binerisasi ini kemudian digunakan sebagai *mask* (topeng) untuk melakukan operasi *Bitwise AND* terhadap citra asli, sehingga latar belakang citra menjadi hitam total dan hanya menyisakan objek uang. Hal ini penting agar fitur yang diekstraksi murni berasal dari uang, bukan dari meja atau alas foto.

2.4 Ekstraksi Fitur (*Feature Extraction*)


Penelitian ini menggunakan pendekatan *Multi Feature Extraction* yang menggabungkan tiga karakteristik visual:

2.4.1 HSV *Color Histogram* (Warna)

Ruang warna HSV (*Hue, Saturation, Value*) lebih merepresentasikan persepsi warna manusia dibandingkan RGB.

- **Hue (H):** merepresentasikan jenis warna.
- **Saturation (S):** merepresentasikan kemurnian atau kekayaan warna.
- **Value (V):** merepresentasikan kecerahan warna.

Dalam penelitian ini, fitur warna diambil dengan menghitung histogram dari komponen H dan S untuk menangkap distribusi warna dominan pada setiap nominal uang tanpa terpengaruh secara signifikan oleh intensitas cahaya (V).




Gambar 2.2 Model Ruang Warna HSV (Hue, Saturation Value)

2.4.2 Local Binary Patterns (LBP) (Tekstur)

LBP adalah operator tekstur yang efisien namun handal. Metode ini bekerja dengan membandingkan nilai piksel pusat dengan piksel tetangganya (biasanya 8 tetangga dalam matriks 3x3). Jika nilai tetangga lebih besar atau sama dengan pusat, diberi nilai 1, jika tidak diberi nilai 0.

Kumpulan nilai biner tersebut kemudian dikonversi menjadi nilai desimal yang merepresentasikan pola tekstur lokal (seperti serat kertas uang). LBP terbukti invarian terhadap perubahan monotonik pada skala abu-abu (Shen & He, 2011).



Gambar 2.3 Ilustrasi Perhitungan Nilai LBP pada Piksel Citra.

2.4.3 Hu Moments (Bentuk)

Untuk mengenali bentuk objek yang mungkin mengalami rotasi atau perubahan skala, digunakan *Hu Moments*. (Ming-Kuei, 1962) merumuskan tujuh momen invarian yang dihitung dari momen pusat ternormalisasi. Fitur ini memastikan bahwa uang yang difoto dalam posisi miring atau terbalik tetap dapat dikenali sebagai nominal yang sama.


2.5 Algoritma Klasifikasi (*Machine Learning*)

Penelitian ini membandingkan kinerja dua algoritma pembelajaran mesin tipe Supervised Learning:

2.5.1 *Support Vector Machine* (SVM)

SVM adalah algoritma yang bekerja dengan mencari *hyperlane* terbaik yang memisahkan antar kelas data dengan *margin* maksimal.

- **Kernel Trick:** Karena data citra sering kali tidak dapat dipisahkan secara linear, penelitian ini menggunakan **Kernel RBF (*Radial Basis Function*)**. Kernel ini memetakan data ke ruang dimensi yang lebih tinggi agar dapat dipisahkan secara linear.
- **Kelebihan:** SVM dikenal stabil dan memiliki kemampuan generalisasi yang baik, terutama pada dataset dengan dimensi fitur yang tinggi (Farhat, 1992).




Gambar 2.4 Konsep Hyperplane dan Margin pada SVM.

2.5.2 *Extreme Gradient Boosting* (XGBoost)

XGBoost adalah pengembangan dari metode *Gradient Boosting* yang menggunakan pendekatan *ensemble learning* berbasis pohon keputusan (*decision trees*).

- **Prinsip Kerja:** XGBoost membangun model secara bertahap (*boosting*), di mana model baru ditambahkan untuk memperbaiki *error* (residual) dari model sebelumnya.
- **Kelebihan:** Algoritma ini dirancang untuk kecepatan komputasi dan skalabilitas tinggi. XGBoost memiliki fitur regularisasi bawaan untuk mencegah *overfitting* (Chen & Guestrin, 2016).



Gambar 2.5 Ilustrasi Struktur Pohon Keputusan (Decision Tree)

2.6 Teknologi Implementasi

2.6.1 ONNX (Open Neural Network Exchange)

ONNX adalah format standar terbuka untuk merepresentasikan model *machine learning*. Format ini memungkinkan model yang dilatih menggunakan *framework* Python (seperti Scikit-Learn atau XGBoost) untuk diekspor dan dijalankan pada lingkungan yang berbeda, seperti aplikasi *mobile*. Keunggulan utama penggunaan ONNX dalam penelitian ini adalah kemampuan **ONNX Runtime** untuk melakukan inferensi (prediksi) secara lokal di perangkat Android (*on-device AI*) dengan latensi rendah, tanpa bergantung pada koneksi internet ke server inferensi.

2.6.2 Supabase

Supabase adalah platform *Backend-as-a-Service* (BaaS) yang menyediakan layanan basis data PostgreSQL secara *real-time*. Dalam aplikasi "Monerize", Supabase digunakan untuk:

1. **Autentikasi:** Mengelola proses *Login* dan *Register* pengguna.
2. **Database:** Menyimpan data riwayat (*history*) deteksi yang dilakukan pengguna, mencakup waktu deteksi dan nominal uang yang terdeteksi.

2.7 Evaluasi Kinerja Model

Untuk mengukur keberhasilan, digunakan metrik evaluasi berdasarkan *Confusion Matrix*:

1. **Akurasi (Accuracy):** Rasio prediksi benar terhadap keseluruhan data.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2. **Presisi (Precision) & Recall:** Digunakan untuk melihat detail performa per kelas, terutama dalam membedakan uang asli dengan kelas *Negative*.

BAB III

METODOLOGI

3.1 Alur Penelitian

Penelitian ini dilakukan melalui serangkaian tahapan sistematis untuk memastikan sistem klasifikasi mata uang Rupiah pada perangkat mobile dapat bekerja dengan optimal. Alur kerja dimulai dari pengumpulan dataset, preprocessing citra, ekstraksi fitur hibrida, pelatihan model, hingga implementasi ke dalam aplikasi Android. Secara garis besar, tahapan penelitian digambarkan sebagai berikut:

1. **Pengumpulan Data:** Mengumpulkan data primer citra uang kertas Rupiah Tahun Emisi 2022 dan citra negative menggunakan kamera *smartphone* dengan variasi latar belakang dan pencahayaan.
2. **Pra-pemrosesan (*Preprocessing*):** Menyeragamkan ukuran citra, mengubah ruang warna, dan melakukan segmentasi objek (penghapusan latar belakang) menggunakan metode *Adaptive Otsu Thresholding*.
3. **Ekstraksi Fitur:** Mengambil informasi karakteristik visual utama, yaitu warna (*HSV Histogram*), Tekstur (*Local Binary Patterns*), dan Bentuk (*Hu Moments*) untuk diubah menjadi vektor numerik.
4. **Pembagian Data:** Memisahkan dataset menjadi dua bagian, yaitu data latih (*training set*) untuk pembelajaran model dan data uji (*testing set*) untuk validasi.
5. **Pemodelan:** Melatih dan membandingkan kinerja dua algoritma *Machine Learning*, yaitu *Support Vector Machine* (SVM) dan *Extreme Gradient Boosting* (XGBoost).
6. **Evaluasi:** Mengukur performa model menggunakan parameter *Confusion Matrix* (Akurasi, Presisi, dan *Recall*).
7. **Implementasi Backend:** Mengonversi model terbaik ke format ONNX (*Open Neural Network Exchange*) dan mengintegrasikannya ke dalam aplikasi *mobile* yang terhubung dengan layanan Supabase.

3.2 Pengumpulan Data (Data Collection)

Data yang digunakan dalam penelitian ini adalah data primer yang diambil secara langsung menggunakan kamera *smartphone*.

1. **Objek Penelitian:** Uang Kertas Rupiah Tahun Emisi (TE) 2022.
2. **Jumlah Data:** Total dataset berjumlah 1.912 citra.
3. **Distribusi Kelas:** Terdiri dari 8 kelas klasifikasi, yaitu:
 - **7 Kelas Nominal:** Rp1.000, Rp2.000, Rp5.000, Rp10.000, Rp20.000, Rp50.000, dan Rp100.000.
 - **1 Kelas Negative:** Citra objek selain uang (seperti dompet, tangan, atau permukaan meja kosong) untuk melatih sistem mengenali objek bukan uang.
4. **Variasi Pengambilan:** Data diambil dengan variasi latar belakang, pencahayaan, dan sudut pengambilan gambar (rotasi) untuk meningkatkan ketahanan model.




Gambar 3.1 Sample Dataset

3.3 Pre-processing

Sebelum dilakukan ekstraksi fitur, citra mentah mengalami tahapan pra-pemrosesan untuk meningkatkan kualitas citra dan memisahkan *Region of Interest* (ROI).

1. **Resize:** Citra diubah ukurannya menjadi dimensi standar (misalnya 300x300 piksel) untuk menyeragamkan masukan dan mempercepat komputasi.
2. **Grayscale:** Mengubah citra RGB menjadi skala keabuan untuk keperluan ekstraksi tekstur dan bentuk.
3. **Gaussian Blur:** Menerapkan filter *Gaussian* untuk mengurangi *noise* visual akibat kualitas kamera.
4. **Adaptive Otsu Thresholding & Masking:** Tahapan ini bertujuan memisahkan uang dari latar belakang. Algoritma Otsu mencari nilai ambang batas otomatis untuk membuat citra biner (hitam-putih). Hasil biner ini digunakan sebagai *mask* (topeng) untuk memotong latar belakang, sehingga fitur yang diekstraksi murni berasal dari area uang.



Gambar 3.2 Alur Preprocessing

3.4 Ekstraksi Fitur

Ini adalah tahapan inti di mana informasi visual diterjemahkan menjadi angka. Sistem ini menggunakan pendekatan Fitur Gabungan (*Concatenated Features*) dengan total panjang vektor fitur sebanyak 469 dimensi. Fitur yang digabungkan adalah:

3.4.1 Fitur Warna (HSV)

Fitur warna diambil dari komponen *Hue* (Warna) dan *Saturation* (Kepekatan) pada ruang warna HSV. Histogram dihitung untuk memetakan distribusi warna dominan pada uang (misalnya merah pada Rp100.000 atau biru pada Rp50.000). Penggunaan HSV meminimalkan dampak perubahan intensitas cahaya (*Value*) yang sering terjadi saat pengambilan foto.

3.4.2 Fitur Tekstur (*Local Binary Pattern – LBP*)

Fitur tekstur diekstraksi menggunakan metode *LBP Uniform* pada citra *grayscale*. LBP bekerja dengan mendeteksi pola mikro seperti sudut, garis, dan bintik pada permukaan uang. Varian *Uniform* dipilih untuk mengurangi dimensi histogram tanpa menghilangkan informasi pola tekstur yang penting, yang menjadi ciri khas kertas uang asli.

3.4.3 Fitur Bentuk (*Hu Moments*)

Fitur bentuk diekstraksi menggunakan 7 invarian momen (*Hu Moments*). Algoritma ini menghitung momen pusat dari citra biner atau *grayscale* untuk menghasilkan 7 nilai skalar yang invarian terhadap:

- Translasi (pergeseran posisi uang)
- Skala (jarak jauh/dekat kamera)
- Rotasi (kemiringan sudut pengambilan)

Vektor-vektor dari ketiga jenis fitur tersebut digabungkan (*concatenated*) menjadi satu vektor panjang dan disimpan dalam format `.joblib` untuk proses pelatihan.

3.5 Pemodelan dan Pelatihan (*Modeling*)

Pada tahap ini, dataset dibagi menjadi data latih (*training set*) dan data uji (*testing set*) dengan rasio tertentu. Dua algoritma dikemangkan dan dibandingkan:

3.5.1 *Support Vector Machine*

1. Menggunakan Kernel RBF (*Radial Basis Function*) untuk menangani data *non-linear*.
2. Parameter seperti C (Regularisasi) dan γ (Gamma) dioptimalkan menggunakan *Grid Search*.

3.5.2 XGBoost (*Extreme Gradient Boosting*) V2

1. Menggunakan objektif multi:*softmax* untuk klasifikasi multikelas.
2. Parameter seperti `max_depth`, `learning_rate`, dan `n_estimators` diatur untuk mencegah *overfitting*.

3.6 Konversi dan Implementasi Sistem

Untuk memungkinkan model berjalan pada perangkat mobile dengan efisien, dilakukan tahapan implementasi teknis sebagai berikut:

1. Konversi Model ke ONNX: Model terbaik yang telah dilatih dalam format Python (Scikit-Learn/XGBoost) dikonversi menjadi format `.onnx` menggunakan pustaka `skl2onnx` atau `onnxmltools`. Hal ini bertujuan agar model dapat dibaca oleh runtime inferensi di Android.
2. Pengembangan Aplikasi *Mobile*: Aplikasi “**Monerize**” dibangun untuk platform Android. Inti aplikasi menggunakan ONNX *Runtime* untuk memuat model dan melakukan prediksi secara lokal (*offline*).
3. Integrasi *Backend* (Supabase):
 - Autentikasi: Implementasi fitur *Login* dan *Register* pengguna.
 - Database: tabel basis data disiapkan untuk menyimpan log aktivitas deteksi (*timestamp* dan nominal) yang dikirim dari aplikasi.

3.7 Evaluasi Kinerja

Kinerja model diukur menggunakan teknik *Confusion Matrix* untuk menghitung metrik:

1. **Akurasi:** Tingkat kebenaran prediksi secara keseluruhan.
2. **Presisi & Recall:** Untuk mengevaluasi seberapa baik model membedakan uang asli dari kelas *negative* dan antar nominal.
3. **Waktu Inferensi:** Mengukur rata-rata waktu yang dibutuhkan aplikasi untuk memproses satu gambar hingga keluar hasil prediksi (detik/milidetik).

BAB IV

HASIL & ANALISA

4.1 Implementasi Sistem

Tahap ini memaparkan hasil implementasi dari perancangan sistem yang telah dilakukan, meliputi lingkungan pengembangan, hasil *preprocessing* citra, hingga antarmuka aplikasi *mobile* “*Monerize*”.

4.1.1 Lingkungan Implementasi

Sistem dikembangkan dan diuji menggunakan spesifikasi perangkat keras dan perangkat lunak sebagai berikut:

1. Perangkat Keras (*Hardware*):

- Laptop (*Processor Core i5/i7/AMD Ryzen, RAM 8GB/16GB*) untuk proses peatihan model.
- *Smartphone* Android untuk pengujian aplikasi *mobile*.

2. Perangkat Lunak (*Software*):

- **Bahasa Pemrograman:** Python (untuk Modeling) dan Dart (untuk Android)
- **Library:** Scikit-learn, XGBoost, OpenCV, ONNX *Runtime*.
- **Backend Service:** Supabase (untuk autentikasi dan database).

4.1.2 Hasil Preprocessing Citra

Sebelum masuk ke tahap klasifikasi, citra uang mengalami proses pemisahan latar belakang menggunakan metode *Adaptive Otsu Thresholding*. Proses ini bertujuan untuk menghilangkan *noise* latar belakang sehingga sistem hanya fokus pada area uang (ROI).

4.1.3 Implementasi Antarmuka Aplikasi

Aplikasi “**Monerize**” berhasil diimplementasikan pada perangkat Android. Berikut adalah tampilan antarmuka utama aplikasi:

1. *Home Page*: Halaman utama Aplikasi




Gambar 4.1 Halaman Home 1



Gambar 4.2 Halaman Home 2


2. *Login*: Pengguna masuk menggunakan akun yang terdaftar di Supabase.



A screenshot of a mobile application's login screen. At the top, there is a back arrow icon. Below it, the text "Welcome Back" is centered. There are two input fields: "Email" and "Password". Below these fields is a green "Login" button. At the bottom, there is a link that says "Don't have an account? Sign Up".

Gambar 4.3 Halaman Login


3. *SignUp*: Pengguna mendaftar dengan menggunakan nama lengkap, *email* dan *password* yang akan disimpan di Supabase.



A screenshot of a mobile application's sign-up screen. At the top, there is a back arrow icon. Below it, the text "Create Account" is centered. There are four input fields: "Full Name", "Email", "Password", and "Confirm Password". Below these fields is a green "Sign Up" button. At the top of the screen, there is a status bar showing the time "3:49" and various icons.


Gambar 4.4 Halaman SignUp

4. Halaman Deteksi: Menampilkan preview kamera dan hasil prediksi nominal secara *real-time*.



Gambar 4.5 Halaman Deteksi

5. Halaman Riwayat: Menampilkan daftar log deteksi yang tersimpan di database.



Gambar 4.6 Halaman Riwayat

4.2 Hasil Pengujian Model

Pengujian ini bertujuan mengukur performa metode *Multi Feature Extraction* (HSV, LBP, *Hu Moments*) terhadap algoritma SVM dan XGBoost. Pengujian dilakukan menggunakan data uji (*testing set*) sebesar 20% dari total 1.912 data.

4.2.1 Pengujian Skenario 1: *Support Vector Machine (SVM)*

Model SVM dilatih menggunakan kernel RBF (*Radial Basis Function*). Berikut adalah hasil visualisasi *Confusion Matrix* dari prediksi model SVM:


```
--- Laporan Klasifikasi SVM ---
      precision    recall  f1-score   support

   1000         0.98         1.00         0.99         48
  10000         1.00         0.94         0.97         48
 100000         0.96         0.98         0.97         48
    2000         0.98         0.98         0.98         48
   20000         1.00         1.00         1.00         48
    5000         0.96         0.98         0.97         45
   50000         1.00         1.00         1.00         46

 accuracy          0.98
 macro avg         0.98         0.98         0.98
weighted avg         0.98         0.98         0.98

Akurasi Keseluruhan: 98.19%
```

Gambar 4.7 Hasil Klasifikasi SVM



Gambar 4.8 Heatmap SVM

Berdasarkan matriks di atas, performa statistik model SVM adalah:

- Akurasi (*Accuracy*): 98.19%
- Presisi Rata-rata: 98.20%
- Recall Rata-rata: 98.18%

4.2.2 Pengujian Skenario 2: *Extreme Gradient Boosting (XGBoost)*

Model XGBoost dilatih dengan parameter objektif multi:softmax. Berikut adalah hasil klasifikasinya:

```

--- Laporan Klasifikasi XGBoost ---
      precision    recall  f1-score   support


   1000         1.00      0.94      0.97         48
  10000         1.00      1.00      1.00         48
 100000         0.98      0.96      0.97         48
   2000         0.98      1.00      0.99         48
  20000         1.00      1.00      1.00         48
   5000         0.96      1.00      0.98         45
  50000         0.98      1.00      0.99         46

 accuracy                   0.98         331
  macro avg                 0.98      0.99      0.98         331
 weighted avg               0.99      0.98      0.98         331

Akurasi Keseluruhan: 98.49%

```

Gambar 4.9 Hasil Klasifikasi XGBoost



Gambar 4.10 Heatmap XGBoost

Berdasarkan matriks di atas, performa statistik model XGBoost adalah:

- Akurasi (*Accuracy*): 98.49%
- Presisi Rata-rata: 98.50%
- Recall Rata-rata: 98.49%

4.2.3 Perbandingan Kinerja Model

Berikut adalah tabel komparasi kinerja antara kedua algoritma berdasarkan hasil pengujian:

Tabel 4.1 Tabel Perbandingan Kinerja Model

Matriks Evaluasi	SVM (RBF)	XGBoost
Akurasi	98.19%	98.49%
Presisi	98.20%	98.50%
Recall	98.18%	98.49%
Ukuran model (ONNX)		

4.3 Pengujian Implementasi Mobile (ONNX)

Pengujian ini dilakukan untuk memastikan mode ONNX dapat berjalan lancar di *smartphone* secara lokal (*on-device*).

4.3.1 Kecepatan Inferensi

Rata-rata waktu yang dibutuhkan aplikasi untuk memproses satu gambar (mulai dari pengambilan citra, *prerocessing*, hingga prediksi keluar) adalah:

- Model SVM (ONNX): ± 12 detik/ms.
- Model XGBoost (ONNX): ± 10 detik/ms.

Hasil menunjukkan bahwa penggunaan format ONNX memungkinkan deteksi dilakukan dengan latensi rendah tanpa bergantung pada kecepatan internet.

4.3.2 Pengujian Fungsionalitas (Supabase)

Pengujian fitur integrasi basis data dilakukan dengan metode *Blackbox Testing*:

Tabel 4.2 Tabel Pengujian Fungsionalitas

Skenario Pengujian	Hasil yang Diharapkan	Hasil Pengujian	Kesimpulan:
Login User	User berhasil masuk ke dashboard	Berhasil	Valid
Simpan Deteksi	Nominal uang tersimpan otomatis ke database	Berhasil	Valid
Load History	Daftar riwayat muncul sesuai akun pengguna	Berhasil	Valid

4.4 Pembahasan

Bagian ini membahas analisis mendalam mengenai hasil yang diperoleh:

1. **Analisis Fitur Hibrida:** Kombinasi fitur Warna (HSV), Tekstur (LBP), dan Bentuk (Hu Moments) terbukti efektif. Fitur **HSV** sangat dominan dalam membedakan nominal dengan warna kontras (misal: Rp100.000 merah vs Rp50.000 biru). Fitur **LBP** membantu membedakan detail serat kertas saat warna tampak pudar, sementara **Hu Moments** menjaga akurasi saat uang terdeteksi dalam posisi miring atau sedikit terlipat.
2. **Analisis Perbandingan Algoritma:** Berdasarkan hasil eksperimen, [XGBoost/SVM] terbukti menjadi algoritma terbaik. Hal ini disebabkan oleh arsitektur *tree boosting* pada XGBoost yang lebih adaptif dalam menangani fitur numerik gabungan dibandingkan SVM yang mencari *hyperplane*. Selain itu, XGBoost menghasilkan model ONNX yang jauh lebih ringan, sehingga sangat cocok untuk implementasi *mobile*.
3. **Efektivitas Implementasi ONNX:** Konversi ke format ONNX menjadi kunci keberhasilan aplikasi "**Monerize**". Model yang awalnya dilatih di lingkungan Python dapat berjalan di Android dengan performa tinggi. Hal ini membuktikan bahwa *Heavy*

Machine Learning tidak selalu harus dijalankan di *Cloud Server*, melainkan bisa di-*deploy* di perangkat pengguna (*Edge Computing*).

4. **Manfaat Fitur History (Supabase):** Integrasi Supabase memberikan nilai tambah fungsional. Aplikasi tidak hanya sekadar alat deteksi sesaat, tetapi juga berfungsi sebagai alat pencatatan (*log*) digital sederhana bagi pengguna untuk melacak uang yang telah mereka pindai.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan perancangan, implementasi, dan pengujian yang telah dilakukan dalam pengembangan aplikasi deteksi nominal uang rupiah “**Monerize**” menggunakan metode *Multi Feature Extraction* dan *Machine Learning*, dapat ditarik kesimpulan sebagai berikut :

1. **Efektivitas Ekstraksi Fitur:** Penerapan metode ekstraksi fitur hibrida yang menggabungkan fitur warna (**HSV**), tekstur (**LBP**), dan bentuk (**Hu Moments**) terbukti mampu merepresentasikan karakteristik uang kertas Rupiah dengan baik. Kombinasi ini efektif membedakan nominal uang meskipun terdapat kemiripan warna atau pola pada beberapa pecahan.
2. **Kinerja Algoritma Terbaik (XGBoost):** Berdasarkan hasil pengujian perbandingan, algoritma *Extreme Gradient Boosting* (**XGBoost**) terbukti lebih unggul dibandingkan *Support Vector Machine* (**SVM**).
 - **XGBoost** menghasilkan akurasi sebesar **98.49%**, Presisi 98.50%, dan Recall 98.49%.
 - **SVM** menghasilkan akurasi sebesar **98.19%**, Presisi 98.20%, dan Recall 98.18%. Selisih kinerja ini, meskipun tipis, menunjukkan bahwa struktur *tree-based* pada XGBoost lebih adaptif dalam menangani variasi fitur citra uang dibandingkan *hyperplane* pada SVM.
3. **Implementasi Mobile (ONNX):** Konversi model ke format **ONNX** (*Open Neural Network Exchange*) berhasil memungkinkan proses klasifikasi berjalan secara *on-device* (lokal) pada perangkat Android tanpa memerlukan koneksi internet untuk proses inferensi. Hal ini membuat aplikasi lebih responsif dan efisien dalam penggunaan sumber daya memori *smartphone*.
4. **Fungsionalitas Sistem:** Integrasi dengan **Supabase** sebagai *backend* berhasil memfasilitasi fitur manajemen pengguna (autentikasi) dan penyimpanan riwayat deteksi (*history logs*), sehingga aplikasi memiliki nilai tambah sebagai alat pencatatan keuangan sederhana bagi pengguna tunanetra maupun umum.

5.2 Saran

Penelitian ini memiliki keterbatasan yang dapat dikembangkan lebih lanjut. Beberapa saran untuk pengembangan sistem di masa mendatang adalah:

1. **Penanganan Variasi Pencahayaan:** Saat ini sistem bekerja optimal pada pencahayaan yang cukup. Pengembangan selanjutnya disarankan menambahkan metode *Illumination Normalization* atau fitur *flash* otomatis pada aplikasi untuk menangani kondisi lingkungan yang minim cahaya (gelap).
2. **Deteksi Uang Lusuh atau Rusak:** Perlu dilakukan penambahan dataset dengan kondisi uang yang lebih ekstrem (sangat lusuh, sobek, atau penuh coretan) untuk

menguji ketahanan model fitur bentuk (*Hu Moments*) dan tekstur (*LBP*) terhadap deformasi fisik uang.

3. **Implementasi *Real-Time Video*:** Aplikasi saat ini berbasis pengambilan citra statis (*capture*). Untuk pengalaman pengguna yang lebih *seamless*, disarankan mengembangkan deteksi berbasis *live stream* video (menggunakan YOLO atau SSD MobileNet) agar pengguna cukup mengarahkan kamera tanpa perlu menekan tombol jepret.
4. **Fitur Deteksi Keaslian Uang:** Sistem saat ini fokus pada klasifikasi nominal. Penelitian selanjutnya dapat mengintegrasikan sensor tambahan atau pengolahan citra *watermark* (tanda air) untuk memberikan fitur peringatan dini terhadap indikasi uang palsu.

DAFTAR PUSTAKA

- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 13-17-Aug*(December), 785–794. <https://doi.org/10.1145/2939672.2939785>
- Farhat, N. H. (1992). Photonit neural networks and learning mathines the role of electron-trapping materials. *IEEE Expert-Intelligent Systems and Their Applications*, 7(5), 63–72. <https://doi.org/10.1109/64.163674>
- Gonzalez, R. C., & Woods, R. E. (2018). Digital Image Processing (4th ed). In *Pearson Education*.
- Ming-Kuei, H. (1962). Visual pattern recognition by moment invariants. *IRE Transactions on Information Theory*, 66–70.
- Qin, S., Auras, A., Cohen, S. B., Crowley, E. J., Moeller, M., Ericsson, L., & Lukasik, J. (2025). *ONNX-Net: Towards Universal Representations and Instant Performance Prediction for Neural Architectures*. 1–16. <http://arxiv.org/abs/2510.04938>
- Shen, L., & He, J. (2011). Face recognition with directional local binary patterns. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 7098 LNCS, 10–16. https://doi.org/10.1007/978-3-642-25449-9_2
- Smith, J. R., & Chang, S. F. (1997). VisualSEEk: A fully automated content-based image query system. *Proceedings of the 4th ACM International Conference on Multimedia, MULTIMEDIA 1996*, 87–98. <https://doi.org/10.1145/244130.244151>